

Cambricon

AI 基础设施架构演进

2015-2026

芯片代际 · 存储与互联 · 系统实现
会议披露 · 软件生态 · 工程取舍

按代际组织，综合会议披露与一手技术资料。
资料截止：2026 年 9 月 28 日。
中文完整版本，与英文版本共享数据、图表及来源。

目录

01 范围与架构主线	3
02 研究谱系：架构会议能证明什么	3
03 商业代际：MLU100、270 与 290	3
04 MLU370：小芯片、融合与板卡差异	4
05 云端加速器与板卡规格	5
06 MLU-Link、系统与网络路线图	8
07 终端 IP、边缘产品与软件延续	11
08 归一化指标与部署含义	15
09 会议索引与产品映射	16
来源映射	18
参考资料	19

01 范围与架构主线

本报告覆盖寒武纪在 2015 年至 2026 年 9 月 28 日公开记录的 AI 基础设施，并以前公司时期的 DianNao 研究为基线。深入梳理思元／MLU 云端加速器、存储、MLU-Link 与 NeuWare；终端 IP 和 MLU220 边缘分支用于解释技术延续。不因公司具有更广泛 AI 战略，就推定存在自研服务器 CPU、商用 DPU 或已交付 AI NIC。

最强的技术延续是可编程领域专用化：机器学习指令接口、张量执行、显式数据搬移，以及横跨云边端的软件平台。商业演进逐步加入更大 SoC、训练支持、小芯片及多设备通信。公开学术记录远比近期商业实现披露丰富，两类证据可以相互解释，但不能视为精确 RTL 谱系。

02 研究谱系：架构会议能证明什么

ASPLOS 2014 的 DianNao 与 MICRO 2014 的 DaDianNao 建立早期神经网络加速研究。ASPLOS 2015 的 PuDianNao 扩展机器学习负载范围；ISCA 2015 的 ShiDianNao 把视觉处理推向传感器附近。作者机构主页明确将 DianNao 名称保留给这些学术设计。因此，本报告将其记录为研究前身，而不是早期商业思元 SKU。

ISCA 2016 的 Cambricon ISA 论文针对固定功能神经网络引擎与通用指令流之间的缺口。领域专用 ISA 可以表达常见神经网络操作，同时保留可编程性。这有助于理解后续 MLU 软件，但若缺少明确对应关系，不能把论文原型的工艺、面积和性能移植到商业 MLU 规格表。

MICRO 2016 的 Cambricon-X 与 MICRO 2018 的 Cambricon-S 研究稀疏及不规则网络。ISCA 2019 的 Cambricon-F 研究分层、自相似编程架构；ISCA 2021 的 Cambricon-Q 面向高效训练。研究主线覆盖稀疏性、可编程性和训练精度，建立工程关注点，但不证明同名机制在每代产品中交付。

Cambricon-F 通过共享指令模型及分层存储组织的节点，递归分解操作，目标是降低不同规模下的编程负担。架构解读：统一接口并未消除放置、归约或拥塞成本，而是改变处理这些成本的位置。论文明确讨论这些挑战，其中研究实例 F1／F100 不等于 MLU100 或 MLU270 产品名称。

2024 年 Cambricon-LLM 研究提出 NPU 配合具有片内处理能力的专用闪存，用于小批量边缘推理。这是容量与带宽协同设计的例子，但不是已披露的思元服务器加速器量产实现。闪存容量、DRAM 中的 KV 存储与计算侧带宽是不同资源。

03 商业代际：MLU100、270 与 290

思元100 于 2018 年建立云端加速器产品线。270 代增加 MLUv02、连接最多十六个张量核心的片上网络、硬件数据压缩及视频／图像功能。官方页面明确给出非稀疏模型的 INT8 128 TOPS，以及 INT4 256 TOPS 和 INT16 64 TOPS。精度变化不能描述为同一负载的架构加速比。

思元290 是面向训练的分支，在 WAIC 2021 与 MLU290-M5 模块及玄思1000／MLU-X1000 系统一同公开展示。其重要性在于从以推理为主的产品叙事，转向多加速器训练与系统软件。本版不从二手产品列表补填缺少板卡匹配依据的 HBM、功耗或浮点速率。训练产品存在与精确实现规格是两种不同陈述。

04 MLU370：小芯片、融合与板卡差异

思元370 采用 7 nm 工艺，将两个 AI 计算小芯片封装为产品，集成 390 亿晶体管。MLUarch03 增加张量单元改进、Supercharger 卷积机制及多算子硬件融合支持。LPDDR5 与 MLU-Link 扩展存储及多设备设计空间。小芯片集成是芯片内部封装边界，双芯板卡则是另一层边界，两者不能混为一谈。

当前官方规格很有说明力：X4 与 X8 都列出 BF16 96 TFLOP/s 和 INT8 256 TOPS，而 X8 把内存容量及带宽加倍至 48 GB、614.4 GB/s。X8 使用两颗思元370，并提供专用 MLU-Link 接口。因此板上两颗芯片不意味着可以把公布的板卡算力再乘二。S4/S8 分支则以较低峰值算力换取 75 W 的紧凑部署条件。

架构解读：X8 配置对数据容量、带宽、编解码资源及多卡通信的关注，不亚于算术密度。即使峰值 BF16 与 X4 相同，它仍可能更适合大型或带宽敏感负载。融合只有在中间数据及执行依赖适合支持机制时才有收益。模型图可移植，也可能仍需调整布局、量化和算子，才能发挥硬件能力。

05 云端加速器与板卡规格

商业参考规格 · 1/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	架构	商用／里程碑	状态	工艺	裸片／封装
思元100 / MLU100	n/d	2018	历史已商用	n/d	n/d
思元270 / MLU270	MLUv02	2019	历史已商用	n/d	n/d
思元290 / MLU290-M5	n/d	2021 公开展示	历史已商用	n/d	n/d
MLU370-S4/S8	MLUarch03	2021-2022 产品时期	已商用／可获取	7 nm	SKU 配置
MLU370-X4	MLUarch03	2021-2022 产品时期	已商用／可获取	7 nm	思元370 芯片
MLU370-X8	MLUarch03	2021-2022 产品时期	已商用／可获取	7 nm	2 思元370 芯片

商业参考规格 · 2/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	计算单元	稠密 BF16	稠密 FP8	稠密 FP6／FP4	FP64 向量／矩阵
思元100 / MLU100	n/d	n/d	n/d	n/d	n/d
思元270 / MLU270	16 张量核心	n/d	n/d	n/d	n/d
思元290 / MLU290-M5	n/d	n/d	n/d	n/d	n/d
MLU370-S4/S8	n/d	72 TFLOP/s 公布值; 稠密口径 n/d	n/d	n/d	n/d
MLU370-X4	n/d	96 TFLOP/s 公布值; 稠密口径 n/d	n/d	n/d	n/d
MLU370-X8	n/d	96 TFLOP/s 公布值; 稠密口径 n/d	n/d	n/d	n/d

商业参考规格 · 3/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	内存: 类型; 堆栈; GB; TB/s	末级缓存 / SRAM
思元100 / MLU100	n/d	n/d
思元270 / MLU270	n/d	n/d
思元290 / MLU290-M5	n/d	n/d
MLU370-S4/S8	LPDDR5; 24/48 GB; 307.2 GB/s	n/d
MLU370-X4	LPDDR5; 24 GB; 307.2 GB/s	n/d
MLU370-X8	LPDDR5; 48 GB; 614.4 GB/s	n/d

商业参考规格 · 4/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	纵向扩展: 链路; 单向 GB/s; 域	主机连接	功耗 / 散热	形态
思元100 / MLU100	n/d	n/d	n/d	云端加速器
思元270 / MLU270	n/d	n/d	n/d	云端加速器
思元290 / MLU290-M5	n/d	n/d	n/d	云端加速器
MLU370-S4/S8	n/d	PCIe4 × 16	75 W; 被动散热	半高 / 半长
MLU370-X4	n/d	PCIe4 × 16	150 W; 被动散热	全高全长; 单槽
MLU370-X8	4 端口; 100 GB/s 单向 聚合; 8 支持板卡	PCIe4 × 16	250 W; 被动散热	全高全长; 双槽

主机 CPU 边界 · 1/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	代号	正式商用	状态	核心微架构	核心／线程
未建立自研主机 CPU 产品	n/a	n/a	n/a	n/a	n/a

主机 CPU 边界 · 2/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	各裸片工艺	裸片／封装	每核 L2	L3／共享域
未建立自研主机 CPU 产品	n/a	n/a	n/a	n/a

主机 CPU 边界 · 3/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	内存：通道；速率；GB/s	插槽／互联	PCIe／CXL	TDP	向量／矩阵 ISA
未建立自研主机 CPU 产品	n/a	n/a	n/a	n/a	n/a

06 MLU-Link、系统与网络路线图

X8 板卡页面澄清一个关键口径：MLU-Link 的 200 GB/s 是聚合双向带宽，对称分配时对应每方向 100 GB/s。页面列出四端口、十六通道及 50 Gb/s 信号速率；本报告保留板级通道／端口表述，不假定每端口十六通道。页面支持八卡服务器配置，但未证明透明内存一致性或全互联拓扑。

2025 年年报描述未来面向训练、语言模型推理、多模态推理及大模型交换的芯片平台。交换芯片项目应放入路线图，而非已交付 AI NIC 或 DPU 表。缺少具名技术披露时，不赋予端口速率、SerDes 代际或交换容量。在已记录的加速器组合中，外部 NIC 与主机 CPU 仍是系统依赖。

网络产品边界 · 1/4

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

产品	商用／里程碑	状态	类别
大模型交换芯片项目	2025 年报	路线图	交换芯片研发
商用 DPU／AI NIC	n/a	未建立产品	n/a

网络产品边界 · 2/4

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

产品	端口×速率	SerDes	主机接口	可编程引擎
大模型交换芯片项目	n/d	n/d	n/d	n/d
商用 DPU／AI NIC	n/a	n/a	n/a	n/a

网络产品边界 · 3/4

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

产品	嵌入式 CPU	板载内存	传输／RDMA	拥塞控制
大模型交换芯片项目	n/d	n/d	n/d	n/d
商用 DPU／AI NIC	n/a	n/a	n/a	n/a

网络产品边界 · 4/4

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

产品	主要卸载	功耗
大模型交换芯片项目	n/d	n/d
商用 DPU／AI NIC	n/a	n/a

MLU370-X8 链路 · 1/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

互联	年份／代际	通道速率	每链路通道	每链路单向 GB/s
MLU-Link	MLU370-X8	50 Gb/s	16 原文所列总量	100 每设备聚合
主机 PCIe	MLU370	16 GT/s	16	~31.5 扣除包开销前

MLU370-X8 链路 · 2/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

互联	每设备链路	拓扑	域规模	一致性／语义
MLU-Link	4 端口	n/d	8-card 支持服务器配置	显式通信；一致性 n/d
主机 PCIe	1	点对点	主机拓扑	PCIe

系统披露 · 1/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

平台	年份／里程碑	CPU／加速器数量	纵向扩展域
玄思1000 / MLU-X1000	WAIC2021	MLU290; 数量 n/d	n/d
MLU370-X8 服务器	产品文档	最高 8 板卡	拓扑 n/d

系统披露 · 2/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

平台	每加速器横向带宽	机架功耗	散热
玄思1000 / MLU-X1000	n/d	n/d	n/d
MLU370-X8 服务器	外部 NIC；n/d	n/d	被动散热板卡；服务器气流

07 终端 IP、边缘产品与软件延续

寒武纪1A、1H 和1M 属于可授权终端处理器 IP 分支，思元220／MLU220 则提供边缘芯片与 M.2／SOM 模组。集成于其他公司 SoC 的 IP 核，不等于寒武纪自有完整 SoC。这些产品与云端方案共享软件和指令家族延续，但存储系统、功耗预算及主机集成方式不同。年报继续描述云端、边缘及 IP 业务，但未公布完整新一代服务器 SKU 矩阵。


NeuWare 将驱动、运行时、算子库及工具整合为共享平台。CNCL 实现神经网络算子，CNCL 提供集合通信，MagicMind 提供基于 MLIR 的推理编译路径。训练支持数据并行、模型并行及混合并行。框架支持只是起点：生产可用性还需要目标规模下的算子覆盖、数值正确性、通信重叠、性能分析与故障恢复。

软件契约

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。


层	产品	功能	范围
平台	NeuWare	驱动／运行时／工具	云／边／端
算子	CNNL / BANG	算子库与内核编程	设备相关调优
通信	CNCL	分布式集合通信	依赖拓扑与配置
推理	MagicMind / MLIR	图编译与优化	依赖模型及算子覆盖

2018-2020 技术栈



功能技术栈；MLU290 与 MLU370 是不同分支，不是组合配置。

2021-2026 disclosures 技术栈



功能技术栈；MLU290 与 MLU370 是不同分支，不是组合配置。

08 归一化指标与部署含义

板级平衡

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

指标	计算	口径
X4 DRAM/BF16	$307.2e9/96e12 = 0.0032 \text{ B/FLOP}$	公布峰值; 稀疏口径未明示
X8 DRAM/BF16	$614.4e9/96e12 = 0.0064 \text{ B/FLOP}$	整板; 非每小芯片
X8 容量/BF16	$48e9/96e12 = 5e-4 \text{ B} \cdot \text{s/FLOP}$	LPDDR, 非 HBM
X8 MLU-Link/DRAM	$100/614.4 = 0.163$	单向聚合链路速率
X4 vs X8 BF16/TDP	$96/150=0.64; 96/250=0.384 \text{ TFLOP/s/W}$	峰值/TDP 代理量; 负载收益不同
HBM/FLOP; 主机 DDR/核心; L3/核心	n/d / n/a	缺匹配公开数据或自有主机 CPU

板卡比较说明峰值每瓦性能为何可能误导：X8 的 BF16/TDP 比低于 X4，却拥有两倍内存带宽与容量，并具备直接多卡通信。带宽受限或容量受限模型因此可能更适合 X8。正确评估需涵盖可用精度、模型容纳能力、主机至设备流量、卡间集合通信及软件版本。来源未说明稀疏口径时，与其他厂商的稠密浮点比较仍需保留条件。

09 会议索引与产品映射

已核实披露谱系 · 1/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

会议／活动	年份	论文／演讲／披露
ASPLOS / MICRO	2014	DianNao / DaDianNao
ASPLOS	2015	PuDianNao
ISCA	2015	ShiDianNao
ISCA	2016	Cambricon ISA
MICRO	2016	Cambricon-X
MICRO	2018	Cambricon-S
ISCA	2019	Cambricon-F
ISCA	2021	Cambricon-Q
WAIC	2021-2022	云端／边缘产品展示

已核实披露谱系 · 2/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

会议／活动	报告人／作者	产品	证据类型	来源
ASPLOS / MICRO	论文作者／公司	研究基线	研究记录	C01 C03
ASPLOS	论文作者／公司	研究	研究记录	C03
ISCA	论文作者／公司	研究	研究记录	C03
ISCA	论文作者／公司	研究 ISA	研究记录	C02
MICRO	论文作者／公司	稀疏性研究	研究记录	C03
MICRO	论文作者／公司	稀疏性研究	研究记录	C03
ISCA	论文作者／公司	研究编程架构	研究记录	C04
ISCA	论文作者／公司	训练研究	研究记录	C03
WAIC	论文作者／公司	MLU220/270/290/370	产品展示	E03 E04

四大架构会议记录以 ISCA、MICRO 和 ASPLOS 最丰富。本版未建立商业 MLU 对应的 HPCA、ISSCC 或 Hot Chips 直接实现论文，也不把同名学术论文当作商业设计证明。近期年报描述大模型研发及部署，但未提供完整具名实现矩阵。因此本报告不为广泛流传的较新型号填入推测工艺、存储或算力；这并不意味着 MLU370 是公司最新部署芯片。

命名边界

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

名称	含义	边界
DianNao family	学术设计	不是商业 MLU SKU
思元 / MLU	芯片及板卡家族	始终注明板卡后缀
MLU370 chiplet / X8 双芯片	封装／板级集成	不同计数层级
MLU-Link / CNCL	硬件链路／集合通信库	带宽与软件行为不同

来源映射

- 01 范围与架构主线 - C02, C03, E02, E03, P01, P02
- 02 研究谱系：架构会议能证明什么 - C01, C02, C03, C04, C05
- 03 商业代际：MLU100、270 与 290 - E02, E03, E05, P01
- 04 MLU370：小芯片、融合与板卡差异 - P02, P04, P05, P06, P07
- 05 云端加速器与板卡规格 - E02, E03, E04, E05, P01, P02, P04, P05, P06
- 06 MLU-Link、系统与网络路线图 - E02, E03, P05, P06
- 07 终端 IP、边缘产品与软件延续 - E02, E03, E05, P01, P02, P06, P07
- 08 归一化指标与部署含义 - E02, P05, P06
- 09 会议索引与产品映射 - C01, C02, C03, C04, E02, E03, E04, P02, P06, P07

参考资料

产品与技术文档

[P01] Siyuan270
<https://cambricon.com/index.php?a=lists&c=index&catid=15&m=content>
一手资料；访问截止 2026-09-28

[P02] Siyuan370
<https://cambricon.com/index.php?a=lists&c=index&catid=360&m=content>
一手资料；访问截止 2026-09-28

[P04] MLU370-S4/S8 board
<https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=365>
一手资料；访问截止 2026-09-28

[P05] MLU370-X4 board
<https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=371>
一手资料；访问截止 2026-09-28

[P06] MLU370-X8 board
<https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=406>
一手资料；访问截止 2026-09-28

[P07] Cambricon NeuWare
<https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=71>
一手资料；访问截止 2026-09-28

会议记录与实现披露

[C01] DianNao project and publication lineage
<https://novel.ict.ac.cn/diannao/>
一手资料；访问截止 2026-09-28

[C02] Cambricon ISA, ISCA2016 author record
<https://researchportal.hkust.edu.hk/en/publications/cambricon-an-instruction-set-architecture-for-neural-networks/>
一手资料；访问截止 2026-09-28

[C03] Tianshi Chen publications
<https://novel.ict.ac.cn/tchen/>
一手资料；访问截止 2026-09-28

[C04] Cambricon-F, ISCA2019 full author paper
<https://dl.yongwei.site/F.pdf>
一手资料；访问截止 2026-09-28

[C05] Cambricon-LLM research, 2024
<https://arxiv.org/abs/2409.15654>
一手资料；访问截止 2026-09-28

发布、生态与部署

[E02] Cambricon2025 annual report, company filing mirror

https://money.finance.sina.com.cn/corp/view/vCB_AllBulletinDetail.php?id=11993143&stockid=688256

一手资料；访问截止 2026-09-28

[E03] WAIC2021 portfolio

<https://www.cambricon.com/index.php?a=show&c=index&catid=127&id=41&m=content>

一手资料；访问截止 2026-09-28

[E04] WAIC2022 portfolio

<https://www.cambricon.com/index.php?a=show&c=index&catid=127&id=51&m=content>

一手资料；访问截止 2026-09-28

[E05] Siyuan220 launch

<https://cambricon.com/index.php?a=show&c=index&catid=127&id=11&m=content>

一手资料；访问截止 2026-09-28