



AI 基础设施架构演进

2015-2026

芯片代际 · 存储与互联 · 系统实现
会议披露 · 软件生态 · 工程取舍

按代际组织，综合会议披露与一手技术资料。
资料截止：2026 年 9 月 28 日。
中文完整版本，与英文版本共享数据、图表及来源。

目录

01 范围与架构主线	3
02 FPGA 基础：Catapult 与 Brainwave	3
03 Cobalt：通用云计算	3
04 Maia 100：建立软件定义机器	5
05 Maia 200：数据流延伸至网络	5
06 Azure Boost、AI NIC 与安全	8
07 系统与编程栈	11
08 归一化平衡与趋势	14
09 会议与产品索引	15
10 命名对照	17
来源映射	18
参考资料	19

01 范围与架构主线

本报告沿微软自研云端芯片，从 FPGA 时代追踪至 Cobalt CPU、Maia 加速器及 Azure Boost 基础设施卸载，覆盖 2015 年至 2026 年 9 月 28 日，并以 2014 年 Catapult 为基线。Azure 中的 AMD、Intel 和 NVIDIA 系统提供部署背景，不改称微软芯片。Xbox 与客户端设备不作深入覆盖。内部生产部署、客户预览与公共虚拟机正式商用分别记录。

贯穿各代的是对数据搬移的显式控制。Catapult 把服务放入可重构网络路径；Maia 暴露分层暂存器、DMA 和同步机制；Boost 把基础设施工作从主机 CPU 卸载。Cobalt 提供通用执行平面。这些互补机器具有不同编程契约，整体价值取决于服务层面的资源隔离与利用率，而非最大的加速器 FLOPS 数字。

02 FPGA 基础：Catapult 与 Brainwave

ISCA 2014 的 Catapult 论文是时期之前的基线，使用分布式 FPGA 加速 Bing 排序。MICRO 2016 的可配置云工作，把重点移向与网络集成的数据中心级可重构网络。ISCA 2018 披露的 Brainwave 把实时神经网络推理映射到 FPGA。该演进的重要之处是：加速器成为服务和网络资源，而不只是挂在一个应用进程旁的外设。

可重构性允许运营方随协议和模型变化迁移功能，但相比专用逻辑会付出面积与能耗成本。后续 ASIC 可以固化稳定操作，同时保留可编程控制。这是架构思路的延续，不证明 Maia 复用某个 Catapult RTL 模块，也不意味着每一代 Boost 都是 FPGA。研究原型、生产基础设施与公共虚拟机产品在时间线上分别处理。

03 Cobalt：通用云计算

Cobalt 100 以 128 个 Neoverse N2 核心建立微软自有 Arm 服务器 CPU 产品线，其虚拟机于 2024 年 10 月正式商用。有效比较应匹配虚拟机配置及服务负载，包括内存、存储和网络限制；处理器核心数本身不能描述客户可见的机器。

Cobalt 200 转向 Neoverse CSS V3 和小芯片实现。微软披露 132 个启用核心、每核 3 MB L2 及 192 MB 共享系统缓存。2026 年 6 月的虚拟机里程碑为早期访问预览，虚拟机规格最高 128 vCPU。132 个物理启用核心与 128 个客户 vCPU 的区别应保留。更大缓存针对数据送至核心的成本，厂商公布的服务收益不代表通用 IPC 倍增。

CPU 代际 • 1/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	代号	正式商用	状态	核心微架构	核心／线程
Cobalt 100	n/d	2024-10	已商用／可获取	Neoverse N2	128 / 128
Cobalt 200	n/d	2026-06 预览	早期访问预览	Neoverse CSS V3	132 / 132

CPU 代际 • 2/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	各裸片工艺	裸片／封装	每核 L2	L3／共享域
Cobalt 100	n/d	n/d	n/d	n/d
Cobalt 200	3 nm	小芯片; 数量 n/d	3 MB	192 MB / SoC

CPU 代际 • 3/3

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

代际／参考 SKU	内存: 通道; 速率; GB/s	插槽／互联	PCIe／CXL	TDP	向量／矩阵 ISA
Cobalt 100	DDR5; 通道/速率 n/d	n/d	n/d	n/d	Armv9
Cobalt 200	n/d	n/d	n/d	n/d	Armv9

04 Maia 100：建立软件定义机器

Hot Chips 2024 补上最初发布所缺的实现细节：约 820 mm² 的 N5 裸片、CoWoS-S 封装、64 GB HBM2e、1.8 TB/s 带宽，以及约 500 MB 本地 SRAM。十六个集群各含四个计算块，分别提供张量、向量、数据搬移与控制功能。幻灯片规格区分 700 W 设计目标与 500 W 配置功耗，两者不能作为可互换工作点。

编译器使用信号量协调异步引擎。Triton 提供较高层路径，Maia API 则显式暴露放置与调度。这以自动缓存管理换取对复用和重叠执行的控制。良好调度可以融合逐元素运算、矩阵计算和通信；不良调度则可能让大规模张量引擎在峰值算力充裕时仍然停顿。幻灯片中的六位、九位张量格式不能改称 FP4 和 FP8。

05 Maia 200：数据流延伸至网络

2026 年技术论文将 Maia 200 描述为软件定义数据流系统，而不是外接网卡的矩阵引擎。单片 3 nm 计算裸片配六堆栈 HBM3e，容量 216 GB、带宽 7 TB/s。四个集群各含九或十个计算块。分离的数据与控制网络、专用 SRAM、DMA 和同步引擎，让软件描述数据何时就绪及其目标位置。公布峰值为 FP4 10,145 TFLOP/s、FP8 5,072 TFLOP/s，TDP 为 750 W。

二十八个集成 400 Gb/s 控制器提供每方向 1.4 TB/s。二十个端口连接固定链路，八个端口接入四个交换平面。论文描述的部署设计点为 6,144 芯片，外部网络存在超额订阅，并非 6,144 芯片全互联内存域。ATLv2 提供传输、加密、选择性重传与拥塞控制。远端 SRAM 访问使用显式发送/接收及同步，不是 CPU 式透明缓存一致性。

架构解读：把通信纳入数据流契约，可以降低启动与主机接口开销，但也把调度责任交给编译器及运行时。实际检验是计算、存储流量与集合通信能否在真实模型形状下重叠。更多低精度算术提高了保持计算受限所需的复用程度，并未消除 HBM 或网络上限。

加速器代际 · 1/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	架构	商用／里程碑	状态	工艺	裸片／封装
Maia 100	软件定义数据流	2023 发布; HC2024	历史已商用	TSMC N5	1 逻辑裸片; CoWoS-S
Maia 200	SDLA	2026 部署	已商用／可获取	3 nm	1 逻辑裸片; 75×75 mm package

加速器代际 · 2/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	计算单元	稠密 BF16	稠密 FP8	稠密 FP6／FP4	FP64 向量／矩阵
Maia 100	64 计算块 / 16 集群	800 TFLOP/s	n/a; 9-bit: 1.5 POPS	6-bit: 3 POPS; FP4 n/d	n/d
Maia 200	4 集群; 9-10 计算块/集群	n/d	5072 TFLOP/s	FP4: 10145 TFLOP/s	n/d

加速器代际 · 3/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	内存：类型；堆栈；GB；TB/s	末级缓存／SRAM
Maia 100	HBM2e; 堆栈 n/d; 64 GB; 1.8 TB/s	~500 MB
Maia 200	HBM3e; 6; 216 GB; 7 TB/s	272 MB

加速器代际 · 4/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	纵向扩展: 链路; 单向 GB/s; 域	主机连接	功耗／散热	形态
Maia 100	12×400G; 600 GB/s 单向; 域 n/d	PCIe5 ×8 (规格表)	700 W 设计／ 500 W 配置	Azure 模块
Maia 200	28×400G; 1400 GB/s 单向; topology-specific	PCIe6 ×8	750 W; 液冷	Azure 模块

Maia 100 幻灯片框图包含较旧 PCIe 标注，而规格表写 PCIe5 ×8；本报告采用规格表，并保留该差异。Maia 200 论文对内存带宽同时出现 TB/s 与 TiB/s 表述；主要规格及厂商架构披露采用 7 TB/s，本报告据此计算。不根据 TDP 与峰值 FLOPS 推定实测应用效率。

06 Azure Boost、AI NIC 与安全

Azure Boost 是基础设施系统，Azure Boost DPU 是其演进中的芯片组件。2024 年 DPU 发布及 2026 年新一代 Boost 正式商用，描述将更多存储与网络功能固化到专用硬件。MANA 提供客户机可见网络接口。最高 400 Gb/s 是支持的平台／虚拟机上限，不证明每个虚拟机都获得该速率。Cerberus 提供硬件信任边界。

基础设施与集成 NIC • 1/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	商用／里程碑	状态	类别
Azure Boost / DPU	2024 发布; 2026 系统正式商用	已商用／可获取	基础设施卸载
Maia 200 ANC	2026	已商用／可获取	集成 AI NIC

基础设施与集成 NIC • 2/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	端口×速率	SerDes	主机接口	可编程引擎
Azure Boost / DPU	最高 400 Gb/s platform	n/d	n/d	专用卸载逻辑
Maia 200 ANC	28×400 Gb/s	n/d	片上 NoC	DMA / ATLv2

基础设施与集成 NIC • 3/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	嵌入式 CPU	板载内存	传输／RDMA	拥塞控制
Azure Boost / DPU	n/d	n/d	MANA / RDMA	n/d
Maia 200 ANC	n/a	共享芯片存储	ATLv2 / Ethernet	Window-based; ECMP / entropy

基础设施与集成 NIC • 4/4

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

产品	主要卸载	功耗
Azure Boost / DPU	网络; 存储; 虚拟化; 信任	n/d
Maia 200 ANC	远端存储; 加密; 重传	包含在 SoC TDP 内

互联层次 · 1/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

互联	年份／代际	通道速率	每链路通道	每链路单向 GB/s
Maia100 Ethernet	2024	400 Gb/s 端口	n/d	50
Maia200 固定 链路	2026	400 Gb/s 端口	n/d	50
Maia200 交换式 链路	2026	400 Gb/s 端口	n/d	50

互联层次 · 2/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

互联	每设备链路	拓扑	域规模	一致性／语义
Maia100 Ethernet	12	直连 + 交换	n/d	显式传输
Maia200 固定 链路	20	托盘固定链路	4 芯片/tray	显式 SDLA 传输
Maia200 交换式 链路	8	4 planes; 2 tiers	6144 设计点	显式传输; 非一致性

07 系统与编程栈

2015-2018 系统角色



功能关系图；不意味着每台 Maia 主机均采用 Cobalt。

2024-2026 系统角色



功能关系图；不意味着每台 Maia 主机均采用 Cobalt。

系统范围 · 1/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

平台	年份／里程碑	CPU／加速器数量	纵向扩展域
Maia100 Azure	2023-2024	n/d	依拓扑
Maia200 部署 design	2026	4 芯片/tray; 最高 6144	固定链路+交换平面
Cobalt200 VMs	2026 预览	最高 128 vCPUs	n/a

系统范围 · 2/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

平台	每加速器横向带宽	机架功耗	散热
Maia100 Azure	n/d	n/d	液冷
Maia200 部署 design	8×400G = 400 GB/s 标称	n/d	液冷
Cobalt200 VMs	VM-specific	n/d	n/d

软件契约

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

层	组件	功能	边界
主机	Arm Linux / Azure VMs	通用服务	VM 限额不同于 SoC
加速器	PyTorch / Triton / Maia API	图、算子、放置	编译器管理暂存器
通信	Maia collectives / ATLv2	集合通信与传输	显式远端数据搬移
基础设施	MANA / Boost / Cerberus	网络、存储、信任	平台与客户机驱动

08 归一化平衡与趋势

推导指标

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

指标	计算	含义
Cobalt200 L3/核心	$192/132 = 1.455 \text{ MB}$	共享容量／启用核心
Maia100 HBM/BF16	$1.8e12/800e12 = 0.00225 \text{ B/FLOP}$	稠密峰值平衡
Maia100 容量/BF16	$64e9/800e12 = 8.0e-5 \text{ B} \cdot \text{s/FLOP}$	容量除以峰值
Maia200 HBM/FP8	$7e12/5072e12 = 0.00138 \text{ B/FLOP}$	与上行格式不同
Maia200 容量/FP8	$216e9/5072e12 = 4.26e-5 \text{ B} \cdot \text{s/FLOP}$	每芯片；十进制字节
Maia200 网络/HBM	$1.4/7 = 0.20$	全部端口单向；并非全为外部链路
Maia200 FP8/TDP	$5072/750 = 6.763 \text{ TFLOP/s/W}$	峰值／TDP 代理量；非实测效率
Cobalt DDR 带宽/核心	n/d	缺匹配内存控制器数据

Maia 换代使 HBM 容量增加至 3.375 倍、带宽增至 3.89 倍，集成网络总带宽增至 2.33 倍。同时数值格式与片上存储组织也改变，因此单一算力增长比会掩盖重要差异。部署决策应测量真实批处理下的延迟、暂存器占用、通信重叠及故障恢复，以判断定制架构提升的是完整服务还是仅某个算子。

09 会议与产品索引

一手披露映射 · 1/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

会议／活动	年份	论文／演讲／披露
ISCA	2014	Catapult
MICRO	2016	A 可配置 Cloud
ISCA	2018	Brainwave
Hot Chips	2024	Inside Maia100
Hot Chips	2026	Maia200
Ignite / Build	2023-2026	Cobalt / Maia / Boost

一手披露映射 · 2/2

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

会议／活动	报告人／作者	产品	证据类型	来源
ISCA	Putnam et al.	FPGA infrastructure	时期前研究基线	C04
MICRO	Microsoft 研究	Catapult	架构／部署	P03
ISCA	Microsoft 研究	FPGA inference	架构论文	C05
Hot Chips	Sherry Xu; Chandru Ramakrishnan	Maia100	完整技术幻灯片	C06
Hot Chips	Microsoft	Maia200	议程与配套技术论文	C03 C01
Ignite / Build	Microsoft	云端产品组合	发布与可用性	E03 E02 E05 E06

ISCA 与 MICRO 建立 FPGA 谱系，Hot Chips 提供 Maia 的模块及实现视图。ISSCC2026 论文 17.4 增加了 Maia 实现披露；官方议程未注明代际后缀。本版未建立 Cobalt/Maia 对应的产品级 HPCA 或 ASPLOS 论文。会议议程证明演讲存在；本文详细规格来自幻灯片、技术论文及产品文档。主要缺口是完整 Cobalt 内存/PCIe 规格、匹配的 Maia 工作点及 SKU 级 Boost 实现细节。

ISSCC 实现披露 · 1/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

会议／活动	年份	论文／演讲／披露
ISSCC	2026	17.4 MAIA: A Reticle-Scale AI Accelerator

ISSCC 实现披露 · 2/2

n/d: 未确定；n/a: 不适用。精度、范围与方向见表内；来源见文末映射。

会议／活动	报告人／作者	产品	证据类型	来源
ISSCC	S. Xu et al.	Maia; generation suffix not in program	官方议程／已发表论文记录；未获取完整文集	C07

ISSCC 记录在 Hot Chips 架构链之外，建立电路/实现披露入口。由于本次未获取完整文集，不能仅根据题目把未披露时钟、电压调节器或 SRAM 电路细节分配给 Maia100 或 Maia200。完整 Hot Chips 幻灯片与 Maia200 技术论文仍是定量实现依据。

10 命名对照

产品与角色

n/d: 未确定; n/a: 不适用。精度、范围与方向见表内; 来源见文末映射。

名称	角色	需区分
Cobalt	通用主机 CPU	Maia
Maia / ANC	AI 加速器／集成网络控制器	Boost DPU
Azure Boost	含专用硬件的基础设施系统	单一固定芯片代际
MANA	微软 Azure 网络适配器	Maia 后端网络

来源映射

- 01 范围与架构主线 - C01, C04, C06, E02, E03, P03, P04
- 02 FPGA 基础：Catapult 与 Brainwave - C04, C05, E06, P03
- 03 Cobalt：通用云计算 - E02, E07, E08, P01
- 04 Maia 100：建立软件定义机器 - C06
- 05 Maia 200：数据流延伸至网络 - C01, C06, P02
- 06 Azure Boost、AI NIC 与安全 - C01, C06, E05, E06, P04
- 07 系统与编程栈 - C01, C06, E02, E06, E07, P04
- 08 归一化平衡与趋势 - C01, C06, P01
- 09 会议与产品索引 - C01, C03, C04, C05, C06, C07, E02, E03, E05, E06, P01, P03, P04
- 10 命名对照 - C01, E02, E06, P04

参考资料

产品与技术文档

[P01] Cobalt200 architecture announcement

<https://techcommunity.microsoft.com/blog/AzureInfrastructureBlog/announcing-cobalt-200-azure%E2%80%99s-next-cloud-native-cpu/4469807>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[P02] Maia200 architecture deep dive

<https://techcommunity.microsoft.com/blog/azureinfrastructureblog/deep-dive-into-the-maia-200-architecture/4489312/>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[P03] Catapult publications and MICRO2016

<https://www.microsoft.com/en-us/research/project/project-catapult/publications/>

官方索引或相关发布资料；完整文档未能下载。

[P04] Azure Boost overview

<https://learn.microsoft.com/en-us/azure/azure-boost/overview>

一手资料；访问截止 2026-09-28

会议记录与实现披露

[C01] Maia200: A Software Defined Dataflow System, 2026

<https://arxiv.org/pdf/2608.24664>

一手资料；访问截止 2026-09-28

[C03] Hot Chips2026 program, Maia200

<https://hc2026.hotchips.org/program/conference/>

官方索引或相关发布资料；完整文档未能下载。

[C04] Catapult ISCA2014

https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/Catapult_ISCA_2014.pdf

官方索引或相关发布资料；完整文档未能下载。

[C05] Brainwave ISCA2018

<https://www.microsoft.com/en-us/research/uploads/prod/2018/06/ISCA18-Brainwave-CameraReady.pdf>

官方索引或相关发布资料；完整文档未能下载。

[C06] Inside Maia100, Hot Chips2024 slides

https://hc2024.hotchips.org/assets/program/conference/day2/81_HC2024.Microsoft.Xu.Ramakrishnan.final.v2.pdf

一手资料；访问截止 2026-09-28

[C07] ISSCC2026 advance program; 17.4 MAIA: A Reticle-Scale AI Accelerator

<https://submissions.mirasmart.com/ISSCC2026/PDF/ISSCC2026AdvanceProgram.pdf>

官方会议议程或新闻资料；不是论文全文。

发布、生态与部署

[E02] Cobalt200 early access preview, June2026

<https://azure.microsoft.com/en-us/blog/new-azure-cobalt-200-vm-deliver-50-performance-improvement-fully-optimized-for-modern-agentic-ai-workloads/>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[E03] Ignite2023 Cobalt Maia Boost

<https://news.microsoft.com/source/features/ai/in-house-chips-silicon-to-service-to-meet-ai-demand/>

官方索引或相关发布资料；完整文档未能下载。

[E05] Azure Boost DPU, Ignite2024

<https://techcommunity.microsoft.com/blog/azureinfrastructureblog/enhancing-infrastructure-efficiency-with-azure-boost-dpu/4298901>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[E06] Next generation Azure Boost GA, 2026

<https://techcommunity.microsoft.com/blog/azurecompute/announcing-the-general-availability-of-the-next-generation-of-azure-boost/4519136>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[E07] Cobalt100 VM general availability, October2024

<https://azure.microsoft.com/en-us/blog/azure-cobalt-100-based-virtual-machines-are-now-generally-available/>

索引或可检索官方页面；产品细节同时参照对应技术文档。

[E08] Arm earnings disclosure: Cobalt N2 and V3

<https://investors.arm.com/static-files/941fd4cb-0027-4e81-9541-66dcd954a14a>

一手资料；访问截止 2026-09-28